

3. Un score d'octroi sur défaut bâlois à 12 mois : enjeux, données de stock et représentativité

Note de rédaction. Les zones encadrées [ZONE . . .] signalent un tableau ou une figure à insérer avec des données internes. Le type d'objet et son contenu attendu sont précisés, et le texte qui suit chaque zone est rédigé comme si l'objet était présent. Les [à compléter] marquent les valeurs chiffrées à renseigner. Pour l'état de l'art, les paginations vérifiées sont indiquées ; les pages internes restées incertaines sont signalées « à confirmer ».

3.1 Refondre un score d'octroi à la fois performant et interprétable

La décision d'octroi de crédit aux professionnels et entrepreneurs retail repose sur un score de différenciation du risque. Ce score ordonne les demandeurs selon leur probabilité de défaut, et le métier en déduit un seuil d'acceptation. Un score est déjà en production sur ce périmètre. Sa refonte est l'objet de cette étude.

Quatre motifs justifient la refonte : un gain de performance attendu, une mise à jour du périmètre, une méthodologie de construction renouvelée et un socle de données enrichi. La contrainte est double. Le score doit mieux discriminer le risque que l'existant, et il doit rester interprétable et traçable, car il appuie une décision opérationnelle et doit être auditable.

Cette double exigence interdit de retenir un modèle de type boîte noire. Elle oriente vers une grille de score logistique, dont la forme reste lisible variable par variable. La performance de cette grille sera toutefois mesurée à l'aune d'une borne supérieure fournie par des modèles non linéaires de référence. Cette borne dira combien de pouvoir discriminant le choix de l'interprétabilité fait éventuellement abandonner.

Le score construit ici est une probabilité de défaut opérationnelle. Il reprend la définition réglementaire du défaut, mais n'est pas développé dans un cadre IRB homologué. Il sert la décision d'octroi en premier lieu, et reste réutilisable pour d'autres usages, par exemple le ciblage commercial.

3.2 Une cible de défaut réglementaire observée à douze mois

L'événement modélisé est le défaut au sens de l'article 178 du règlement (UE) 575/2013 (CRR). Un débiteur est en défaut lorsqu'il accuse plus de quatre-vingt-dix jours d'arriérés sur une obligation significative, ou lorsque l'établissement juge improbable qu'il honore l'intégralité de ses engagements sans réalisation de garanties. La fenêtre d'observation du défaut est fixée à douze mois après la date d'observation.

Cette définition est celle d'un score de différenciation du risque, à distinguer d'une PD réglementaire au sens strict. Aucune calibration through-the-cycle ni marge de conservatisme réglementaire n'est imposée. La calibration au taux de défaut est traitée comme secondaire, pour les raisons exposées en section 5.6.

L'approche retenue s'inscrit dans une littérature établie. La construction d'une grille de score par discrétisation des variables puis régression logistique sur les poids de la preuve est la démarche praticienne de référence (Siddiqi, 2017, chapitre consacré au regroupement des variables et au calcul du *weight of evidence*, pagination exacte à confirmer sur l'édition utilisée). La revue de Hand et Henley (1997, *Journal of the Royal Statistical Society, Series A*, 160(3), p. 523-541) recense les méthodes de classification appliquées au crédit et discute l'effet dit de *flat maximum* : sur ces données, de nombreux modèles atteignent une performance voisine, si bien que le choix d'un modèle peut se fonder sur d'autres critères que la seule qualité d'ajustement, comme la stabilité ou la finesse du contrôle du taux de refus (la discussion du *flat maximum* figure dans la section comparative de la revue, page précise à confirmer). Les comparaisons empiriques récentes confirment ce constat. Le benchmark de Lessmann, Baesens, Seow et Thomas (2015, *European Journal of Operational Research*, 247(1), p. 124-136) place les méthodes d'ensemble en tête sur de nombreux jeux de données de crédit, tout en soulignant des écarts modérés. Gunnarsson, vanden Broucke, Baesens, Óskarsdóttir et Lemahieu (2021, *European Journal of Operational Research*, 295(1), p. 292-305) montrent que le gradient boosting de type XGBoost domine les autres méthodes considérées, et que les réseaux profonds ne le surpassent pas. Ces résultats motivent l'usage d'XGBoost comme outil interne de la construction, et le maintien d'une régression logistique interprétable comme modèle final.

3.3 Un échantillonnage sur stock à deux dates : pseudo-indépendance et limites

La modélisation porte sur le stock de clients observé à deux dates espacées de six mois. Chaque observation associe l'état des variables explicatives à une date d'observation et la réalisation du défaut sur les douze mois qui suivent. L'empilement des deux dates augmente le nombre d'observations et vise une pseudo-indépendance entre elles.

Cette pseudo-indépendance est une approximation, à assumer comme telle. Un même emprunteur peut figurer aux deux dates, ce qui introduit une corrélation intra-emprunteur via des variables qui évoluent lentement. De plus, les deux fenêtres de performance de douze mois se chevauchent sur six mois, si bien que les défauts associés aux deux observations d'un même client ne sont pas indépendants. La conséquence pratique est une sous-estimation des écarts-types, donc des tests de significativité optimistes lors du binning et de la sélection. Cette limite est quantifiée en section 5.5 au moyen d'erreurs-types robustes en clusters par emprunteur.

[ZONE — Figure 1 : frise temporelle du design d'échantillonnage] Type : *schéma chronologique (timeline)*. Représenter l'axe du temps avec les deux dates d'observation D1 et D2 espacées de six mois, et, sous chacune, la fenêtre de performance de douze mois associée. Faire apparaître la zone de chevauchement de six mois entre les deux fenêtres. Légende autonome rappelant que le défaut est observé sur les douze mois suivant chaque date d'observation.

La figure 1 illustre ce dispositif. Les deux fenêtres de performance se recouvrent sur leur seconde moitié, ce qui matérialise la source de corrélation entre les deux observations d'un

même client. Ce schéma justifie de traiter la structure des données comme un panel plutôt que comme un échantillon de tirages indépendants.

3.4 Du stock à la production : un test out-of-time et out-of-population

Le modèle est appris sur le stock de l'année 2024. Les données de production de l'année 2025 servent d'échantillon de validation hors période d'apprentissage. Cet échantillon est doublement extérieur. Il est out-of-time, puisque postérieur à la période d'apprentissage. Il est aussi out-of-population, puisqu'il décrit un flux de demandeurs à l'octroi, alors que l'apprentissage porte sur un stock de clients existants.

Le choix de modéliser sur 2024 mérite justification, car la consigne interne privilégie les données les plus récentes. La cible exige un recul de douze mois pour que le défaut soit observable. La production 2025 ne dispose donc pas encore de sa fenêtre de performance complète. Elle est exploitable comme population d'application, mais non comme support d'apprentissage de la cible.

La distinction entre population de modélisation et population d'application fonde une question de représentativité, traitée en section 5.4. Pour isoler l'effet de population de l'effet de temps, une comparaison entre le stock 2024 et la production 2024, à millésime constant, est conduite par un test à deux échantillons.

3.5 Trois sous-périmètres, et un filtrage par les libellés réservé au Pros-ER

Le périmètre se découpe en trois sous-périmètres métier bien définis : les professionnels et entrepreneurs retail hors associations et SCI, désignés Pros-ER ; les associations ; les sociétés civiles immobilières (SCI). Le Pros-ER représente l'essentiel de la production. Un modèle distinct est construit pour chaque sous-périmètre.

[ZONE — Tableau 1 : volumétrie et sinistralité par sous-périmètre] *Type : tableau.*
Colonnes : sous-périmètre ; effectif (nombre d'observations) ; part de la production ; taux de défaut à douze mois. Lignes : Pros-ER, Associations, SCI, Total. Titre autonome précisant le millésime (stock 2024) et la définition du défaut.

Le tableau 1 fixe les ordres de grandeur. Le Pros-ER concentre environ quatre-vingts pour cent de la production [part exacte à compléter], avec un effectif de [à compléter] observations et un taux de défaut de [à compléter]. Les associations et les SCI représentent des volumes plus faibles, [à compléter] et [à compléter] observations, et des taux de défaut respectifs de [à compléter] et [à compléter]. Ces écarts de sinistralité et de volumétrie justifient à eux seuls la séparation des trois modèles.

Une source de données supplémentaire provient de l'analyse des libellés de transaction. Son exploitation exige un historique minimal de cinq transactions mensuelles. En deçà, les variables issues des libellés ne sont pas renseignées de façon fiable. Ce filtrage définit donc à la fois une sous-population et un jeu de variables distinct.

Le filtrage par les libellés est restreint au seul Pros-ER. Des tests récents montrent que les associations et les SCI sont insensibles à ce filtrage : l'ajout des variables de libellés n'y

améliore pas la différenciation du risque [référence interne ou résultat à compléter]. Restreindre l'analyse des libellés au Pros-ER est donc une décision fondée sur ces tests, et non une simplification de convenance. La question de savoir si ces libellés justifient un modèle spécialisé sur le Pros-ER fait l'objet du test comparatif de la section 5.3.

[ZONE — Figure 2 : distribution du nombre de transactions mensuelles dans le Pros-ER] Type : *histogramme*. Abscisse : nombre de transactions mensuelles par client. Ordonnée : effectif ou densité. Tracer une ligne verticale au seuil de cinq transactions et annoter la part de la population située au-delà. Légende autonome indiquant le périmètre (Pros-ER, stock 2024).

La figure 2 montre la répartition des clients du Pros-ER selon leur intensité transactionnelle. La part des clients atteignant au moins cinq transactions mensuelles s'élève à [à compléter] pour cent. Cette proportion est déterminante : si elle est faible, le gain potentiel des libellés ne concerne qu'une fraction réduite de la production, ce qui pèsera sur l'arbitrage entre un modèle général et deux modèles spécialisés.

3.6 Construction et appariement des sources de données

Les variables proviennent de plusieurs sources internes, appariées par identifiant client et date d'observation. Elles couvrent les caractéristiques signalétiques, les éléments comptables, l'historique de la relation bancaire, et, pour la sous-population concernée, les agrégats issus des libellés de transaction. Le traitement respecte le cadre du RGPD.

[ZONE — Figure 3 : schéma relationnel des tables] Type : *diagramme entité-association*. Représenter les tables sources (signalétique, comptable, relation bancaire, libellés) et la table cible (défaut à douze mois), reliées par les clés d'appariement (identifiant client, date d'observation). Indiquer la cardinalité des liens. Légende autonome décrivant le sens de lecture.

La figure 3 décrit l'appariement. Chaque observation de la table d'analyse résulte de la jointure des tables sources sur le couple identifiant client et date d'observation, puis de l'adjonction de la cible calculée sur la fenêtre de douze mois. Ce schéma fixe l'unité statistique : un couple client-date, et non un client.

3.7 Le traitement des valeurs manquantes : modalité dédiée et valeurs sentinelles

Deux régimes de traitement des valeurs manquantes coexistent, selon la nature de la variable. Pour la majorité des variables, une modalité « manquant » est créée et conservée comme catégorie à part entière. Le caractère éventuellement informatif de l'absence est ainsi préservé jusqu'au binning.

Pour les variables comptables, l'absence est codée par une valeur sentinelle hors domaine, selon le cas 0, -1 ou 1. Ce codage répond à une hypothèse de manquant informatif, de type MNAR : pour ces variables, l'absence de donnée comptable est elle-même un signal de risque, par exemple l'absence de bilan déposé ou un compteur jamais initialisé. La valeur sentinelle est choisie hors du domaine des valeurs observées, afin que l'arbre de

discrétisation puisse isoler ce groupe ou le rattacher à la classe de risque pertinente, sans le confondre avec une valeur numérique plausible.

[ZONE — Tableau 2 : taux de valeurs manquantes et régime de traitement par famille de variables] *Type : tableau.* Colonnes : famille de variables ; taux de valeurs manquantes ; régime de traitement (modalité dédiée ou valeur sentinelle) ; hypothèse sous-jacente (informatif ou non). Lignes par famille (signalétique, comptable, relation bancaire, libellés). Titre autonome précisant le périmètre et le millésime.

Le tableau 2 récapitule l'ampleur du phénomène. Les variables comptables présentent les taux de manquants les plus élevés, jusqu'à [à compléter] pour cent, ce qui rend leur traitement déterminant. La justification du caractère informatif de ces manquants, et la sensibilité du modèle à ce choix par rapport à une simple modalité « manquant » en *weight of evidence*, sont discutées en section 5.5.

3.8 Pourquoi l'inférence des refusés n'est pas nécessaire

Les scores d'octroi souffrent classiquement d'un biais de sélection : la performance n'est observée que sur les demandeurs acceptés, et l'inférence des refusés cherche à corriger cette censure. Ce biais ne s'applique pas ici.

Le défaut bâlois est observé sur l'ensemble du stock de clients, quel que soit le statut d'acceptation à l'origine de la relation. La cible n'est donc pas censurée par la décision d'octroi passée. Aucune correction par inférence des refusés n'est requise, et n'en est appliquée. Ce point est explicité car la littérature sur le sujet est abondante et le jury en attend la justification.

3.9 Premiers éléments descriptifs

Les statistiques descriptives sont limitées à ce qui éclaire les enjeux et la structure des données. Le tableau 1 fournit les taux de défaut et la volumétrie par sous-périmètre. La figure 2 fournit la part de la population du Pros-ER exploitable par les libellés. Le tableau 2 fournit l'ampleur des valeurs manquantes par famille de variables.

Ces éléments suffisent à cadrer la suite. Le déséquilibre de la cible, avec un taux de défaut de [à compléter] pour cent sur le Pros-ER, oriente le choix des métriques d'évaluation vers des mesures indépendantes du seuil, présentées en section 4. La concentration de la production sur le Pros-ER justifie d'en faire le fil conducteur des résultats, les associations et les SCI étant synthétisées. Les analyses descriptives complémentaires figurent en annexe.