

Plan détaillé du mémoire de fin d'études (cadre ENSAI, 30 p. hors annexes)

Thèse défendue (à valider avant d'écrire)

Une grille de score logistique dont la discrétisation est pilotée par un boosting de souches (XGBoost profondeur 1) constitue une refonte plus performante que le score existant tout en restant interprétable et traçable ; elle se situe près de la borne atteignable par des modèles non linéaires, ce qui montre que les interactions apportent peu sur ce périmètre ; et sur le seul Pros-ER, un modèle général unique suffit (ou non) face à deux modèles spécialisés avec et sans libellés de transaction.

Le verdict du test A/B est la chute du mémoire, tout le plan l'amène. À formuler en une phrase non technique pour l'introduction.

Budget de pages (impératif)

Section	Pages	Statut
0. Résumé	0,5	rédigé en dernier
1. Introduction	1	rédigé en dernier
2. Environnement du stage	0,5	
3. Problématique et données	~6	
4. Inférence statistique	~6	
5. Discussion	~15	coeur du mémoire
6. Conclusion	1	rédigé en dernier
7. Bibliographie	1	citations seulement

Tout ce qui déborde part en annexe : pré-traitement, tables de binning, tableaux de coefficients, encadrés méthodologiques longs.

0. Résumé (0,5 p., en dernier)

Langage usuel, non statistique. Le problème (refonte d'un score d'octroi), la démarche, le résultat principal (gain vs existant, proximité de la borne non linéaire, verdict du test A/B libellés), la préconisation.

1. Introduction (1 p., en dernier)

- Contexte du crédit aux professionnels et entrepreneurs retail, enjeu de la décision d'octroi.
- La question : refondre un score d'octroi existant, score de différenciation du risque sur défaut à 12 mois.
- La thèse défendue, en une phrase.
- La démarche scientifique, sans jargon.

2. Environnement du stage (0,5 p.)

BNP Paribas, équipe Model Design (RISK BCEF Architecture), périmètre de l'équipe, fonction du maître de stage, insertion de la mission. Court.

3. Problématique et données (~6 p.)

Titre informatif, ex. « *Un score d'octroi sur défaut bâlois à 12 mois : enjeux, données de stock et représentativité* ».

- **Enjeux et difficultés.** Pourquoi refondre l'existant (performance, périmètre, méthode, données). Double exigence performance / interprétabilité. Positionnement opérationnel, hors cadre IRB strict. Annoncer en une phrase que la performance sera bornée par des modèles non linéaires de référence.
- **Cible.** Défaut réglementaire (CRR art. 178 : 90 jours d'arriérés + *unlikeliness to pay*), fenêtre 12 mois. **État de l'art compact ici** (4-5 citations : Hand & Henley pour le flat maximum, Siddiqi, Lessmann et al., Gunnarsson et al.), pas de chapitre dédié.
- **Qualité et structure des données.** Sources, volumétrie, RGPD. Design sur le stock à deux dates espacées de 6 mois (pseudo-indépendance), avec mention des fenêtres de performance 12 mois chevauchantes et de la corrélation intra-emprunteur (renvoi robustesse 5.5).
- **Stock 2024 vs production 2025.** La production 2025 sert d'échantillon out-of-time, qui est aussi out-of-population (stock vers flux). Justifier de modéliser sur 2024 malgré la consigne interne « données récentes » : recul de 12 mois nécessaire pour observer le défaut.
- **Les trois sous-périmètres**, comme découpage métier établi : Pros-ER hors associations et SCI (environ 80 % de la production), Associations, SCI. Donc trois modèles.
- **Filtrage par transactions et libellés**, restreint au seul Pros-ER, justifié par les tests récents montrant Associations et SCI insensibles au filtrage. À écrire comme une décision fondée sur des tests, pas une commodité. Seuil de 5 transactions mensuelles : sous-population et jeu de variables distinct. Annoncer le test A/B.
- **Schéma causal et relationnel** de la génération des données (appariement des tables).
- **Valeurs manquantes.** Modalité « missing » en général ; valeurs sentinelles (0 / -1 / 1) pour les variables comptables, manquant informatif (MNAR), pour forcer le

regroupement par l'arbre. **[Contribution]** justification MNAR et condition « hors domaine ».

- **Pourquoi pas de reject inference.** Le défaut bâlois est observé sur tout le stock, accepté ou refusé : pas de biais de sélection. À écrire explicitement, le jury l'attend.
- Statistiques descriptives strictement utiles (taux de défaut et volumétrie par sous-périmètre, part des clients à au moins 5 transactions dans le Pros-ER, taux de manquants).

4. Inférence statistique (~6 p.)

Titre informatif, ex. « Une grille logistique à discrétisation pilotée par boosting de souches ».

Fil directeur imposé par le règlement : du plus simple au plus complexe, désormais complet.

- **Référence basse.** Régression logistique brute, point de départ. Sa limite (non-linéarités, effets de seuil) motive la discrétisation. Notations propres, définies.
- **Modèle retenu.** Grille logistique sur variables binnées en WoE. Écrire le modèle ; définir WoE et IV en encadré court, détails en annexe.
- **Discrétisation par souches boostées.** XGBoost de profondeur 1 = modèle additif sans interaction (lignée GAM / EBM). Extraction des points de coupure, fusion et regroupement pour imposer monotonie, sens du risque, stabilité, significativité ; validation métier des variables qualitatives. **[Contribution]** optimisation des hyperparamètres XGBoost en amont du binning.
- **Réduction de la redondance.** Clusters de corrélation Spearman puis Cramér's V, élimination par instabilité a priori et jugement métier. Encodage ordinal des qualitatives par le sens du risque (pour homogénéiser Spearman). **[Contribution]**.
- **Sélection des variables.** Forward stepwise sur WoE par gain marginal d'IV en validation croisée (environ 30 vers 10-12), puis LASSO de contrôle. **[Contribution]**.
- **Référence haute.** Challengers non linéaires, posés en quelques lignes seulement : famille, rôle de borne de performance, couple additif (profondeur 1) vs profondeur supérieure pour tester les interactions. Non développés ici ; hyperparamètres en annexe.
- **Validation succincte** (métriques annoncées, détail en section 5) et lecture métier du modèle final.

5. Discussion (~15 p.) — coeur du mémoire

Titre informatif, ex. « Performance, parcimonie et représentativité : ce que vaut la refonte ».

Ici vivent les résultats et toute la critique. Sous-sections à titres informatifs.

5.1 Le modèle retenu et sa performance. Trois grilles, Gini/AUC, KS. Pros-ER en fil rouge, Associations et SCI synthétisés en tableau. Dégradation contrôlée en out-of-time (production 2025), stabilité (PSI).

5.1bis Jusqu'où peut-on aller ? Borne de performance et valeur des interactions. Écart Gini/KS grille vs challengers non linéaires, par sous-périmètre. Le prix de l'interprétabilité, lu via le flat maximum. Test additif (profondeur 1) vs profondeur supérieure pour quantifier l'apport des interactions. SHAP sur le challenger pour vérifier que ses *risk drivers* coïncident avec ceux de la grille. [Contribution].

5.2 La refonte bat-elle l'existant ? Comparaison directe au score en place, même périmètre, courbes ROC, gains par tranche. Justification chiffrée de la refonte.

5.3 Un modèle général suffit-il sur le Pros-ER ? (test A/B libellés) La question centrale. Modèle général unique sur tout le Pros-ER vs deux modèles (au moins 5 transactions avec libellés, moins de 5 sans). Pour attribuer un gain aux libellés et non à la spécialisation de population, comparaison à **population au moins 5 transactions constante** : général sans libellés vs spécialisé avec libellés. Situer chaque option par rapport à la borne challenger. Arbitrage performance vs coût de maintenir deux modèles et un pipeline de libellés. Verdict.

5.4 Le modèle est-il représentatif de la population d'octroi ? Le stock sert à modéliser, le flux à décider : test à deux échantillons. [Contribution] C2ST (XGBoost + AUC + SHAP) sur stock 2024 vs production 2024, à temps constant, pour isoler l'effet population de l'effet temps. Variables responsables via SHAP, lecture métier, conséquence pour l'usage.

5.5 Robustesse des choix méthodologiques. Exigée par le règlement. Pour chaque choix, l'alternative et son effet :

- binning boosté multivarié vs binning univarié monotone (sensibilité à la corrélation des variables) ;
- manquants par sentinelles vs modalité WoE dédiée ;
- stepwise vs LASSO (convergence sur les 10-12 variables) ;
- erreurs-types robustes en clusters par emprunteur (structure de panel, fenêtres chevauchantes) ;
- optimisme de la validation croisée du stepwise vs estimation propre en out-of-time.

Argument transversal du challenger : si ses variables importantes (SHAP) coïncident avec celles de la grille, la sélection est robuste ; sinon, limite à discuter.

5.6 Atouts, limites et portée. Écart au cadre IRB homologué. Calibration volontairement secondaire : le métier fixe le seuil par taux de défaut cible chez les acceptés, donc classement et taux de défaut observé par tranche suffisent.

6. Conclusion (1 p., en dernier)

Aide à la décision, pas bilan personnel. Rappel bref de l'enjeu, enseignements par rapport à la problématique, **préconisations à BNP** (quel modèle déployer par sous-périmètre, garder un ou deux modèles sur le Pros-ER, logique de seuil, surveillance et re-binning), perspective court terme. Langage usuel.

7. Bibliographie (1 p.)

Uniquement les références citées dans le corps. Éviter les photocopies de cours.

Annexes (hors quota de pages)

- Compléments problématique (schéma relationnel détaillé).
 - Compléments données (descriptives étendues, taux de manquants par variable).
 - Méthodologie détaillée : pré-traitement complet, encadrés WoE/IV, tables de binning, hyperparamètres des challengers.
 - Validation : tables de coefficients, courbes complètes, résultats détaillés du C2ST, robustesse étendue.
 - **Bilan personnel** des compétences acquises (1-2 p.).
 - Inventaire de l'usage de l'IA générative si la filière le demande.
-

Ordre de production des résultats

1. Trois modèles de base et comparaison au score existant (5.1, 5.2) : la colonne vertébrale, à sécuriser en premier.
2. Challengers non linéaires comme borne, et test additif vs interactions (5.1bis) : rapide à entraîner, cadre tout le reste en disant d'emblée si la grille est proche du plafond.
3. Test A/B libellés sur Pros-ER au moins 5 transactions (5.3).
4. C2ST représentativité (5.4).
5. Robustesse (5.5).

Si le calendrier se tend, 5.2, 5.1bis et 5.3 portent le mémoire ; 5.4 et 5.5 le font passer de correct à très bon mais sont sacrificables. Garder les deux fronts ouverts (refonte vs existant, et test A/B) jusqu'à ce que les premiers chiffres tombent : si la part des clients à au moins 5 transactions est faible ou le gain des libellés marginal, le centre de gravité bascule vers 5.2 et 5.4.

Rappels de forme (critères d'évaluation ENSAI)

- Titres informatifs partout, bannir « Présentation des modèles et résultats », « Analyse descriptive », etc.
- Figures et tableaux autonomes (lisibles sans le texte), numérotés, titrés, référencés sans « la figure ci-dessus ».
- Pas de copies d'écran, pas de code pour décrire un modèle.
- Contribution personnelle identifiable (les blocs [Contribution]).

- Du simple au complexe ; un paragraphe = une idée ; phrases courtes.
- Reproductibilité : un expert doit pouvoir refaire l'étude à la lecture.